DETEKSI PERUBAHAN DEFORESTASI MENGGUNAKAN SIAMESE U-NET PADA CITRA SATELIT MULTISPEKTRAL

ALDI PRAMUDYA

PROGRAM STUDI ILMU KOMPUTER
SEKOLAH SAINS DATA, MATEMATIKA, DAN INFORMATIKA
INSTITUT PERTANIAN BOGOR
BOGOR
2026

PERNYATAAN MENGENAI SKRIPSI DAN SUMBER INFORMASI SERTA PELIMPAHAN HAK CIPTA

Dengan ini saya menyatakan bahwa skripsi dengan judul "*DETEKSI PERUBAHAN DEFORESTASI MENGGUNAKAN SIAMESE U-NET PADA CITRA SATELIT MULTISPEKTRAL*" adalah karya saya dengan arahan dari dosen pembimbing dan belum diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka di bagian akhir skripsi ini.

Dengan ini saya melimpahkan hak cipta dari karya tulis saya kepada Institut Pertanian Bogor.

Bogor, Juni 2026

Aldi Pramudya
G6401231003

ABSTRAK

ALDI PRAMUDYA. Deteksi Perubahan Deforestasi Menggunakan *Siamese U-Net* Pada Citra Satelit Multispektral. Dibimbing oleh AHMAD RIDHA dan MEDRIA KUSUMA DEWI HARDIHENATA.

Deforestasi merupakan ancaman serius bagi keanekaragaman hayati dan keseimbangan iklim global, terutama di hutan tropis Indonesia. Metode deteksi perubahan tutupan lahan konvensional seringkali kurang efektif dalam menangani kompleksitas citra multispektral dan variabilitas kondisi atmosfer. Penelitian ini bertujuan mengembangkan model deteksi perubahan tutupan lahan akibat deforestasi secara otomatis menggunakan arsitektur *Siamese U-Net* berbasis *deep learning* pada citra Sentinel-2. Model dirancang dengan dua cabang *encoder* berbobot bersama (*weight sharing*) untuk mengekstraksi fitur dari sepasang citra multi-temporal, lalu digabungkan pada modul *decoder* guna menghasilkan peta perubahan biner. Performa model akan dievaluasi menggunakan metrik *F1-score*, *Intersection over Union* (IoU), dan akurasi keseluruhan, serta dibandingkan dengan beberapa metode pembanding. Penelitian ini diharapkan dapat menunjukkan keunggulan pendekatan *Siamese U-Net* dalam mendeteksi deforestasi secara akurat guna mendukung sistem pemantauan hutan berbasis *remote sensing* secara operasional.

Kata kunci: deforestasi, deteksi perubahan, *deep learning*, Sentinel-2, *Siamese U-Net*

ABSTRACT

ALDI PRAMUDYA. Deforestation Change Detection Using Siamese U-Net On Multispectral Satellite Imagery. Supervised by AHMAD RIDHA and MEDRIA KUSUMA DEWI HARDIHENATA.

Deforestation poses a serious threat to global biodiversity and climate stability, particularly in Indonesian tropical forests. Conventional land cover change detection methods are often inadequate in handling the complexity of multispectral imagery and atmospheric variability. This study aims to develop an automated land cover change detection model for deforestation using a Siamese U-Net deep learning architecture on Sentinel-2 satellite imagery. The model is designed with two weight-sharing encoder branches to extract features from a pair of multi-temporal images, which are then fused within a decoder module to generate a binary change map. Model performance will be evaluated using F1-score, Intersection over Union (IoU), and overall accuracy, and compared against alternative methods. The results of this study are expected to demonstrate the superiority of the Siamese U-Net approach in accurately detecting deforestation to support operational remote sensing-based forest monitoring systems.

Keywords: change detection, deep learning, deforestation, Sentinel-2, Siamese U-Net

© Hak Cipta milik IPB, tahun 2026
Hak Cipta dilindungi Undang-Undang

Dilarang mengutip sebagian atau seluruh karya tulis ini tanpa mencantumkan atau menyebutkan sumbernya. Pengutipan hanya untuk kepentingan pendidikan, penelitian, penulisan karya ilmiah, penyusunan laporan, penulisan kritik, atau tinjauan suatu masalah, dan pengutipan tersebut tidak merugikan kepentingan IPB.

Dilarang mengumumkan dan memperbanyak sebagian atau seluruh karya tulis ini dalam bentuk apa pun tanpa izin IPB.

Judul	:	Deteksi Perubahan Deforestasi Menggunakan *Siamese U-Net* Pada Citra Satelit Multispektral
Nama	:	Aldi Pramudya
NIM	:	G6401231003

Disetujui oleh

Pembimbing 1:
Ahmad Ridha, S.Kom., M.S. _____

Pembimbing 2:
Medria Kusuma Dewi Hardhienata, S.Kom., Ph.D. _____

Diketahui oleh

Ketua Program Studi:
Dr. Sony Hartono Wijaya, S.Kom., M.Kom. _____
NIP. 198108092008121002

Dekan Sekolah Sains Data, Matematika, dan Informatika:
Prof. Dr. Ir. Agus Buono, M.Si., M.Kom. _____
NIP. 196607021993021001

PRAKATA

Puji dan syukur penulis panjatkan kepada Allah *subhanaahu wa ta'ala* atas segala karunia-Nya sehingga proposal penelitian ini berhasil diselesaikan. Tema yang dipilih dalam penelitian yang direncanakan untuk dilaksanakan selama 4 bulan ini ialah deteksi perubahan tutupan lahan akibat deforestasi, dengan judul "*Deteksi Perubahan Deforestasi Menggunakan Siamese U-Net Pada Citra Satelit Multispektral*".

Penyusunan proposal penelitian ini juga tidak lepas dari dukungan dan bantuan dari berbagai pihak. Oleh karena itu, penulis menyampaikan terima kasih kepada:

1. Ahmad Ridha, S.Kom., M.S. dan Medria Kusuma Dewi Hardhienata, S.Kom., Ph.D. selaku komisi pembimbing yang telah membimbing, memberikan arahan, serta banyak masukan berharga.
2. Seluruh bapak dan ibu dosen Program Studi Ilmu Komputer yang telah membagi ilmu dan membimbing penulis selama masa studi.
3. Ibunda tercinta, Juwairiyah, yang senantiasa memberikan doa, perhatian, dan kasih sayang yang luar biasa bagi penulis.
4. Bapak Dian Pramudya serta keluarga besar penulis atas doa, dukungan, dan kasih sayangnya yang tiada henti.
5. Walid Nadirul Ahnaf, Adhiya Radhin Fasya, Naufal Akmal Rizqulloh, Aghnat Hasya Sayyidina, dan Ahmad Zaidan Al-Anshory sebagai kawan yang memberi saran, rekomendasi, serta bantuan dalam penyusunan proposal ini.
6. Semua teman-teman di Ilmu Komputer angkatan 60 atas kebersamaan dan dukungannya.

Semoga proposal penelitian ini bermanfaat bagi pihak yang membutuhkan dan bagi kemajuan ilmu pengetahuan.

Bogor, Juni 2026

Aldi Pramudya

DAFTAR ISI

DAFTAR TABEL x
DAFTAR GAMBAR xi
I PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Rumusan Masalah 1
1.3 Tujuan 2
1.4 Manfaat 2
1.5 Ruang Lingkup 2
1.6 Hipotesis 2
II TINJAUAN PUSTAKA 3
2.1 Remote Sensing dan Citra Satelit Multispektral 3
2.2 Deteksi Perubahan pada Citra Satelit 3
2.3 Deep Learning untuk Deteksi Perubahan 3
2.4 Siamese Network untuk Deteksi Perubahan 4
2.5 Arsitektur Lanjutan untuk Deteksi Perubahan 4
2.6 Explainable Artificial Intelligence 4
2.7 Research Gap 5
III METODE 6
3.1 Data Penelitian 6
3.2 Alat 6
3.3 Akuisisi Data dan *Cloud Masking* 6
3.4 Pra-pemrosesan Data 7
3.5 Arsitektur Model 7
3.6 Pelatihan Model 8
3.6.1 Loss Function 8
3.6.2 Optimizer dan Learning Rate 8
3.6.3 Prosedur Pelatihan 9
3.6.4 Augmentasi Data 9
3.6.5 Reproducibility 9
3.7 Analisis *Explainable Artificial Intelligence* (Grad-CAM) 9
3.7.1 Dasar Teknis 9
3.7.2 Implementasi 10
3.7.3 Sampel Analisis 10
3.7.4 Kriteria Validasi Kualitatif 10
3.8 Analisis Data 11
3.8.1 Metrik Evaluasi Kuantitatif 11
3.8.2 Interpretasi Kualitatif XAI 11
IV SIMPULAN 13

DAFTAR PUSTAKA 14
RIWAYAT HIDUP 16

DAFTAR TABEL

1 Kategori sampel analisis Grad-CAM 10

DAFTAR GAMBAR

1 Diagram alur tahapan penelitian (*data pipeline*) 6
2 Diagram blok arsitektur Siamese U-Net 8

I PENDAHULUAN

1.1 Latar Belakang

Deforestasi adalah perubahan fungsi hutan menjadi penggunaan lahan lain, terlepas dari apakah hal itu disebabkan oleh manusia atau tidak (Food and Agriculture Organization, 2023). Konversi hutan tropis menjadi perkebunan monokultur telah berlangsung secara masif selama dua dekade terakhir. Dari 2002 sampai 2024, Kalimantan Barat kehilangan 1.4 Mha hutan primer basah, menyumbang 33% dari total kehilangan tutupan pohon dalam periode yang sama. Area total hutan primer basah di Kalimantan Barat berkurang 20% dalam periode waktu ini (Global Forest Watch, 2026).

Deteksi perubahan pada citra satelit adalah tugas utama dalam *remote sensing* yang tak hanya dapat diaplikasikan dalam kasus pemantauan lingkungan, namun juga pada kasus lain seperti penilaian bencana dan perencanaan perkotaan. Metode *pixel-based* tradisional seperti diferensiasi citra, pembandingan, dan regresi hanya bersandar kepada perbandingan spektral atau intensitas (Richards, 2022). Walaupun secara komputasi lebih efisien, pendekatan tradisional rentan terhadap noise, variasi pencahayaan, dan ketidakselarasan geometrik sehingga membatasi ketahanan pada kondisi nyata (Ali et al., 2026; Richards, 2022).

Deep Learning (DL) telah berkembang dan berhasil merevolusi bidang ini dengan memungkinkan pembelajaran fitur secara otomatis. *TransSiamUNet*, sebuah arsitektur DL yang mengombinasikan *Siamese networks*, *U-Net segmentation*, dan *Vision Transformers* (ViT) berhasil mendeteksi perubahan pada dataset LEVIR-CD dengan *F-1-score* 0,928 (Ali et al., 2026).

Meskipun menunjukkan hasil yang menjanjikan, arsitektur *TransSiamUNet* memiliki kompleksitas tinggi dan membutuhkan sumber daya yang besar, sehingga kurang efisien untuk implementasi pada kasus yang mengharuskan keterbatasan sumber daya. Selain itu, model DL memiliki kecenderungan bersifat *black box*, sehingga sulit untuk memahami proses inferensi model. Kurangnya interpretabilitas dapat menurunkan tingkat kepercayaan serta menghambat penerapan pada aplikasi kritis seperti pemantauan lingkungan.

Oleh karena itu, penelitian ini mengusulkan pendekatan berbasis DL untuk mendeteksi perubahan deforestasi di Kalimantan menggunakan citra satelit multispektral. Secara khusus, penelitian ini berfokus pada pengembangan arsitektur *Siamese U-Net* yang dimodifikasi untuk mencapai keseimbangan antara performa dan efisiensi, serta mengintegrasikan teknik *Explainable Artificial Intelligence* (XAI) guna meningkatkan interpretabilitas model.

1.2 Rumusan Masalah

1. Bagaimana performa model *deep learning* (Siamese U-Net) dalam mendeteksi perubahan deforestasi pada citra multispektral Sentinel-2 di Kalimantan?

2. Apakah modifikasi arsitektur Siamese U-Net dapat meningkatkan performa deteksi perubahan dibandingkan model baseline?

3. Bagaimana *Explainable Artificial Intelligence* (Grad-CAM) dapat digunakan

untuk menginterpretasikan hasil deteksi perubahan?

1.3 Tujuan

1. Mengimplementasikan dan mengevaluasi model Siamese U-Net untuk deteksi perubahan deforestasi.
2. Mengembangkan modifikasi arsitektur untuk meningkatkan performa model berdasarkan teknik evaluasi *Intersection over Union* (IoU) dan *F-1-Score*.
3. Menganalisis interpretabilitas model menggunakan metode *Explainable Artificial Intelligence* (Grad-CAM).

1.4 Manfaat

1. Memberikan kontribusi dalam pengembangan metode *deep learning* untuk deteksi perubahan tutupan lahan berbasis citra multispektral, khususnya melalui eksplorasi arsitektur *Siamese U-Net* dan pendekatan *Explainable AI*.
2. Menyediakan pendekatan yang dapat digunakan untuk mendukung pemantauan deforestasi secara lebih efisien dan terotomatisasi.

1.5 Ruang Lingkup

1. Penelitian difokuskan pada deteksi perubahan deforestasi menggunakan citra satelit multispektral.
2. Wilayah studi dibatasi pada Kalimantan sebagai studi kasus.
3. Data yang digunakan adalah citra Sentinel-2 Level-2A dan label dari Hansen Global Forest Change.
4. Pendekatan yang digunakan terbatas pada model *deep learning* berbasis U-Net, khususnya *Siamese U-Net* dan variasi modifikasinya.
5. Tahapan penelitian mencakup pra-pemrosesan data, pelatihan model, dan evaluasi performa menggunakan metrik seperti IoU dan F1-score.
6. Analisis interpretabilitas dilakukan menggunakan metode *Explainable Artificial Intelligence* (*Grad-CAM*).
7. Penelitian ini tidak mencakup pengembangan sistem produksi berskala besar, dan visualisasi hasil dilakukan secara terbatas untuk keperluan analisis.

1.6 Hipotesis

1. Model *Siamese U-Net* mampu mendeteksi perubahan deforestasi pada citra multispektral Sentinel-2 dengan performa yang baik.
2. Modifikasi arsitektur *Siamese U-Net* dapat meningkatkan performa deteksi perubahan dibandingkan model baseline.
3. Pendekatan *Explainable AI* (*Grad-CAM*) mampu memberikan interpretasi yang relevan terhadap hasil prediksi model.

II TINJAUAN PUSTAKA

2.1 Remote Sensing dan Citra Satelit Multispektral

Remote sensing adalah proses mengambil informasi dari sebuah objek tanpa kontak langsung, menggunakan sensor yang dipasang pada satelit, pesawat udara, *drone*, atau wahana udara (Richards, 2022; Withanage, 2024).

Sentinel-2 yang dikembangkan oleh *European Space Agency* (ESA) dalam program Copernicus, merupakan salah satu satelit observasi bumi paling relevan untuk analisis tutupan lahan. Sentinel-2 membawa sensor *Multispectral Imager* (MSI) dengan 13 band spektral pada resolusi spasial 10 hingga 60 meter per piksel (Copernicus Data Space Ecosystem, n.d.).

Band Near-Infrared (NIR, B8) dan *Short-Wave Infrared* (SWIR, B11–B12) sangat sensitif terhadap kondisi kesehatan dan kerapatan vegetasi, menjadikannya sangat relevan untuk deteksi deforestasi. Indeks vegetasi seperti *Normalized Difference Vegetation Index* (NDVI) yang diturunkan dari band merah dan *Near Infra-red* (NIR) telah lama mendominasi pemetaan vegetasi, namun diketahui mengalami saturasi pada kanopi hutan yang padat dan bernilai tinggi (Chrysostomou et al., 2026).

Pada kasus wilayah tropis seperti Kalimantan, tantangan utama penggunaan citra optis adalah tutupan awan yang tinggi. Menggabungkan beberapa citra dalam rentang waktu tertentu untuk menghasilkan piksel bebas awan dapat dilakukan secara efisien melalui platform Google Earth Engine.

2.2 Deteksi Perubahan pada Citra Satelit

Deteksi perubahan (change detection) adalah proses mengidentifikasi perbedaan kondisi suatu area pada dua atau lebih waktu berbeda dari data *remote sensing*. Aplikasinya mencakup pemantauan lingkungan, penilaian bencana, perencanaan perkotaan, dan pemantauan deforestasi (Cheng et al., 2023).

Metode deteksi perubahan awal berbasis *image differencing* diperkenalkan oleh Weismiller et al. pada tahun 1977 menggunakan data multispektral Landsat untuk memantau lingkungan pesisir (Jiang et al., 2024). Pendekatan tradisional seperti *image differencing*, *thresholding*, dan regresi hanya bersandar pada perbandingan spektral atau intensitas piksel secara langsung. Meskipun komputasi lebih efisien, metode ini rentan terhadap *noise*, variasi pencahayaan antar-akuisisi, dan ketidakselarasan geometrik, sehingga membatasi keandalannya pada kondisi nyata. Keterbatasan inilah yang mendorong pengembangan pendekatan berbasis *deep learning* yang lebih robust.

2.3 Deep Learning untuk Deteksi Perubahan

Deep learning memungkinkan model untuk mempelajari representasi fitur secara hierarkis langsung dari data mentah, tanpa rekayasa fitur manual. *Convolutional Neural Network* (CNN) menjadi fondasi utama dalam analisis citra, karena kemampuannya mengekstrak fitur spasial lokal melalui operasi konvolusi berlapis Purwono et al. (2023).

U-Net (Ronneberger et al., 2015) adalah arsitektur *encoder-decoder* yang dirancang awalnya untuk segmentasi citra medis, namun terbukti efektif di berbagai

domain termasuk *remote sensing*. Pada eksperimen yang dilakukan oleh Yang et al. (2024), U-Net yang dimodifikasi dengan *attention-mechanism* SimAM dan CBAM berhasil mendapatkan akurasi sebesar 95.23% dan MIoU (*Mean Intersection of Union*) sebesar 84.56%.

Performa model dalam tugas deteksi perubahan umumnya dievaluasi menggunakan metrik seperti *Intersection over Union* (IoU), *precision*, *recall*, dan *F1-score*, yang mengukur kesesuaian antara hasil prediksi dan label *ground truth*.

2.4 Siamese Network untuk Deteksi Perubahan

Siamese network adalah arsitektur yang terdiri dari dua subjaringan identik dengan bobot yang digunakan bersama (*shared weights*), didesain untuk memproses dua input secara paralel dan menghasilkan representasi yang dapat dibandingkan (Chen and He, 2020). Konsep ini pertama diperkenalkan oleh Bromley et al. (1993) untuk verifikasi tanda tangan, kemudian diadaptasi secara luas untuk tugas *change detection* pada citra satelit.

Dalam konteks *change detection*, arsitektur *Siamese* CNN dibangun untuk mendapatkan representasi fitur yang distinktif antara piksel-piksel dari dua citra temporal yang berbeda (Peng et al., 2025). Dengan memproses citra sebelum (t_1) dan citra setelah (t_2) melalui encoder yang identik, model belajar mengekstrak fitur yang *invariant* terhadap variasi musim dan pencahayaan, sehingga perbedaan fitur yang terdeteksi benar-benar mencerminkan perubahan fisik di lapangan. Pendekatan Siamese lebih robust dibandingkan metode tradisional karena secara langsung memodelkan perbedaan temporal dalam ruang fitur, tak hanya membandingkan nilai piksel mentah (Lei et al., 2026). Keterbatasan utamanya adalah kemampuan pemodelan konteks global yang terbatas pada arsitektur berbasis CNN murni, serta belum optimalnya penanganan citra multispektral yang *multiband* seperti Sentinel-2.

2.5 Arsitektur Lanjutan untuk Deteksi Perubahan

Untuk mengatasi keterbatasan pemodelan konteks global pada CNN, arsitektur hybrid yang menggabungkan CNN dengan *Vision Transformer* (ViT) mulai mendominasi penelitian terkini. BIT merupakan metode berbasis transformer yang menggunakan kemampuan pemodelan global transformer untuk melakukan diferensiasi fitur melalui *semantic tokens*, meningkatkan informasi kontekstual dalam jaringan konvolusi sehingga menghasilkan *change map* yang lebih baik (Chen et al., 2021).

TransSiamUNet, yang mengombinasikan *Siamese networks*, *U-Net segmentation*, dan *Vision Transformers*, mencapai akurasi tertinggi sebesar 0,941 dan F1-score 0,874 pada dataset OSCD, menunjukkan superioritas konsisten dibandingkan *baseline* yang kuat Ali et al. (2026). Namun demikian, kompleksitas tinggi dan kebutuhan sumber daya komputasi yang besar menjadi hambatan utama untuk penerapan pada kondisi dengan keterbatasan infrastruktur.

2.6 Explainable Artificial Intelligence

Model DL cenderung bersifat *black box*, menghasilkan prediksi yang akurat namun sulit dipahami proses inferensinya. *Explainable Artificial Intelligence* (XAI) adalah bidang yang bertujuan membuat keputusan model AI dapat diinterpretasikan

oleh manusia, meningkatkan kepercayaan dan akuntabilitas sistem.

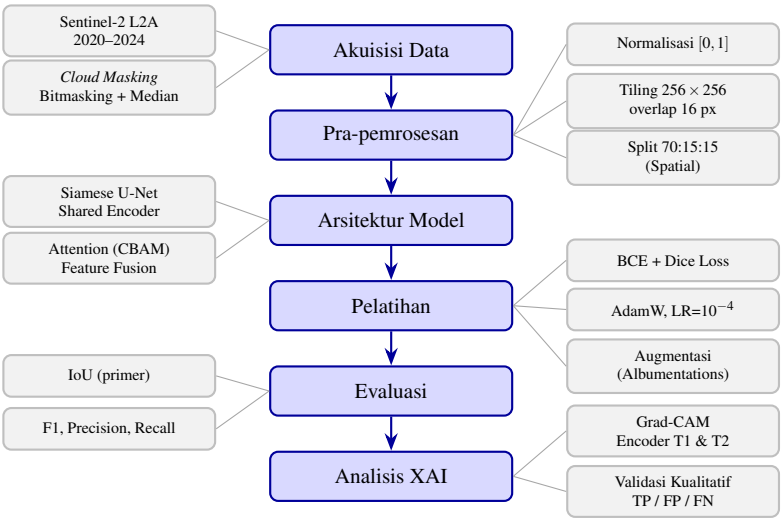
Grad-CAM (*Gradient-weighted Class Activation Mapping*) diperkenalkan oleh Selvaraju et al. (2016) sebagai teknik XAI yang menggunakan gradien dari konsep target yang mengalir ke lapisan konvolusi terakhir untuk menghasilkan peta lokalisasi kasar yang menyoroti region penting dalam citra untuk memprediksi konsep tersebut. Secara teknis, Grad-CAM menghitung bobot kepentingan setiap feature map melalui *global average pooling* atas gradien, kemudian menghasilkan *heatmap* sebagai kombinasi linear terbobot dari *feature maps* tersebut yang dilewatkan fungsi ReLU. Grad-CAM unggul dalam efisiensi komputasi dan memberikan kepercayaan yang dapat diterima, menjadikannya cocok untuk konteks yang sensitif terhadap kecepatan inferensi. Dalam konteks remote sensing, Grad-CAM memungkinkan verifikasi apakah model benar-benar memperhatikan area yang mengalami perubahan vegetasi, bukan artefak atau noise citra. Ini adalah hal yang penting untuk membangun kepercayaan pada aplikasi pemantauan lingkungan (Cheng et al., 2025).

2.7 Research Gap

Dari tinjauan literatur di atas, beberapa celah penelitian dapat diidentifikasi. Pertama, metode tradisional *change detection* terbukti tidak cukup robust untuk kondisi citra satelit tropis yang kompleks. Kedua, arsitektur seperti *TransSiamUNet* mencapai performa tinggi namun memiliki kompleksitas yang membuatnya kurang praktis untuk digunakan secara luas. Ketiga, meskipun XAI telah banyak diterapkan pada domain medis dan klasifikasi umum, penerapannya pada *change detection* untuk pemantauan deforestasi masih sangat terbatas dalam literatur. Keempat, sebagian besar penelitian menggunakan dataset bangunan perkotaan (LEVIR-CD, WHU-CD) sehingga performanya pada citra multispektral vegetasi tropis seperti Sentinel-2 belum teruji secara komprehensif. Oleh karena itu, penelitian ini mengusulkan *Siamese U-Net* yang dimodifikasi untuk mencapai keseimbangan antara performa dan efisiensi, dengan integrasi *Grad-CAM* untuk meningkatkan interpretabilitas model pada konteks deteksi deforestasi di Kalimantan menggunakan citra Sentinel-2.

III METODE

Penelitian ini terdiri atas enam tahap utama, yaitu akuisisi data, *preprocessing* data, pembangunan model, pelatihan, evaluasi, dan diakhiri analisis menggunakan XAI. Bagan alur tahapan penelitian secara keseluruhan disajikan pada Gambar 1.



Gambar 1 Diagram alur tahapan penelitian (*data pipeline*)

3.1 Data Penelitian

Penelitian ini menggunakan data sekunder berupa citra satelit Pulau Kalimantan yang diakuisisi dari *Sentinel-2 Level-2A Collection* Tahun 2020 hingga 2024. Label ground truth diambil dari *Hansen Global Forest Change* lapisan *lossyear* sebagai binary mask deforestasi.

3.2 Alat

Alat yang digunakan sebagai berikut:

- *Google Earth Engine* (GEE) sebagai alat akuisisi data dan pra-pemrosesan citra satelit.
- Python 3.11 dengan library: PyTorch, NumPy, Rasterio, GDAL, scikit-learn
- Platform training: Kaggle Notebook dengan GPU T4

3.3 Akuisisi Data dan *Cloud Masking*

Citra *Sentinel-2 Level-2A* diakuisisi melalui GEE untuk dua periode waktu yang merepresentasikan kondisi sebelum $(\text{pre}, T1)$ dan sesudah $(\text{post}, T2)$ deforestasi. Untuk meminimalkan pengaruh tutupan awan dilakukan metode *bitmasking* dan *median compositing*. Teknik *cloud masking* secara efektif menghilangkan piksel yang terkontaminasi awan dengan menggunakan *bitmask* spektral yang telah ditentukan sebelumnya, sedangkan teknik *median compositing* merekonstruksi gambar bebas awan dengan memilih nilai median dari serangkaian pengamatan waktu. Pendekatan ini meminimalkan pengaruh nilai-nilai yang menyimpang, menjaga

keakuratan spektral, serta memberikan solusi yang efisien secara komputasi untuk menghilangkan awan dan bayangan awan. (Kathiroli et al., 2025).

Band yang digunakan dipilih berdasarkan relevansinya terhadap deteksi vegetasi: B2 (Blue), B3 (Green), B4 (Red), B8 (NIR), B11 dan B12 (SWIR), serta indeks turunan NDVI.

Label deforestasi diturunkan dari dataset Hansen Global Forest Change, menggunakan layer *lossyear* untuk membentuk binary change mask (1 = deforestasi, 0 = tidak berubah), yang kemudian diselaraskan secara spasial dengan citra Sentinel-2.

3.4 Pra-pemrosesan Data

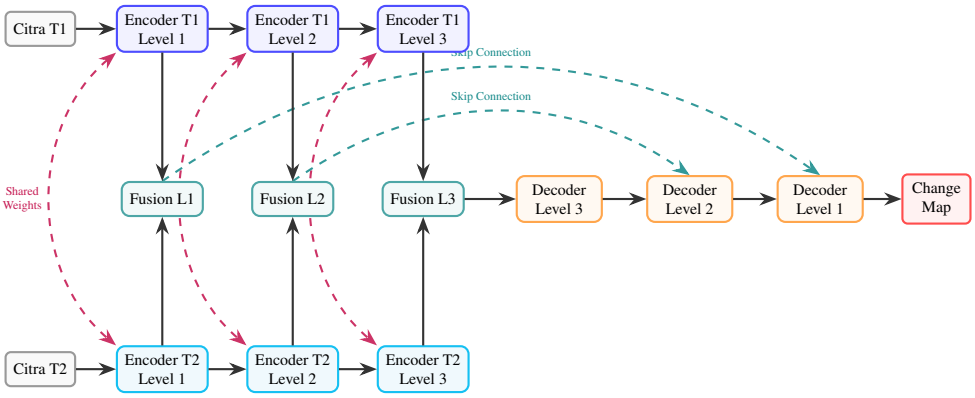
Citra hasil akuisisi diproses melalui tahapan berikut:

1. Normalisasi nilai piksel ke rentang $[0, 1]$.
2. *Tiling* citra menjadi patch berdimensi 256×256 piksel dengan overlap 16 piksel untuk memastikan kontinuitas fitur di batas patch.
3. Penanganan *class imbalance* dengan *weighted loss* karena area deforestasi umumnya minoritas.
4. Pembagian dataset secara spasial dilakukan menggunakan metode *Pythagorean tiling* (Youssef et al., 2023) dengan membagi wilayah studi menjadi pola menyerupai papan catur dengan rasio luas blok 70:30. Blok yang lebih besar (70%) digunakan sebagai data pelatihan (*training*), sedangkan blok yang lebih kecil (30%) dibagi rata masing-masing sebesar 15% untuk data validasi (*validation*) dan data pengujian (*test*) guna menghindari kebocoran data spasial antar patch yang berdekatan.

3.5 Arsitektur Model

Penelitian ini mengembangkan arsitektur *Siamese U-Net* sebagai model baseline, kemudian mengusulkan modifikasi arsitektur untuk meningkatkan performa.

Model Baseline *Siamese U-Net*: Dua encoder identik dengan shared weights memproses citra T1 dan T2 secara paralel. Fitur dari kedua encoder digabungkan (feature differencing atau concatenation) pada setiap level, kemudian didekode oleh decoder U-Net tunggal untuk menghasilkan binary change map berukuran sama dengan input. Diagram blok arsitektur model Siamese U-Net disajikan pada Gambar 2.



Gambar 2 Diagram blok arsitektur Siamese U-Net

Modifikasi yang Dieksplorasi (bersifat eksploratif, dipilih berdasarkan hasil ablation study):

1. Penambahan attention mechanism (CBAM atau SimAM) pada *encoder* untuk memfokuskan model pada fitur spektral yang relevan.
2. Modifikasi modul *feature fusion* dengan membandingkan antara *absolute differencing*, *concatenation*, dan *element-wise multiplication*
3. Penyesuaian kedalaman encoder untuk keseimbangan performa–efisiensi.

Pemilihan modifikasi final didasarkan pada hasil *ablation study* menggunakan metrik IoU pada validation set.

3.6 Pelatihan Model

Pelatihan dilakukan menggunakan pendekatan *supervised learning* dengan konfigurasi berikut.

3.6.1 Loss Function

Kombinasi *Binary Cross-Entropy* (BCE) dan *Dice Loss* digunakan sebagai fungsi objektif:

$$\mathscr{L} = \lambda_{BCE} \cdot \mathscr{L}_{BCE} + \lambda_{Dice} \cdot \mathscr{L}_{Dice} \tag{III.1}$$

BCE menghukum kesalahan prediksi per piksel secara individual, sedangkan *Dice Loss* secara langsung mengoptimasi *overlap* antara prediksi dan *ground truth* — yang merupakan proksi langsung dari IoU. Kombinasi keduanya efektif menangani *class imbalance* karena *Dice Loss* tidak terpengaruh dominasi kelas mayoritas. Bobot λ ditentukan melalui *hyperparameter tuning* awal dengan nilai awal $\lambda_{BCE} = 0.5$ dan $\lambda_{Dice} = 0.5$.

3.6.2 Optimizer dan Learning Rate

Optimizer AdamW digunakan dengan *weight decay* 10^{-4} untuk regularisasi implisit. *Learning rate* awal ditetapkan sebesar 10^{-4} dengan strategi penjadwalan *ReduceLROnPlateau* yaitu *learning rate* diturunkan sebesar faktor 0.5 apabila *validation* IoU tidak meningkat selama 5 epoch berturut-turut. Batas minimum *learning rate* ditetapkan 10^{-6}.

3.6.3 Prosedur Pelatihan

Model dilatih hingga maksimal 100 *epoch* dengan mekanisme *early stopping* berdasarkan *validation* IoU (*patience* = 10 *epoch*). Bobot model terbaik disimpan berdasarkan nilai *validation* IoU tertinggi selama pelatihan, bukan berdasarkan *epoch* terakhir. Konfigurasi *batch size* disesuaikan dengan kapasitas GPU yang tersedia.

3.6.4 Augmentasi Data

Augmentasi diterapkan secara *online* selama pelatihan menggunakan library Albumentations, meliputi: *random horizontal* dan *vertical flip* ($p = 0.5$), *random rotation* 90° ($p = 0.5$), serta *random brightness/contrast shift* ringan ($p = 0.2$) untuk mensimulasikan variasi akuisisi antar-tanggal. Augmentasi tidak diterapkan pada *validation* dan *test set*.

3.6.5 Reproducibility

Random seed ditetapkan secara konsisten pada seluruh library (Python, NumPy, PyTorch, CUDA) untuk memastikan hasil pelatihan dapat direproduksi. Seluruh konfigurasi *hyperparameter* dicatat menggunakan file konfigurasi YAML.

3.7 Analisis *Explainable Artificial Intelligence* (Grad-CAM)

3.7.1 Dasar Teknis

Grad-CAM (*Gradient-weighted Class Activation Mapping*) diusulkan oleh Selvaraju et al. (2016) sebagai teknik XAI yang menggunakan informasi gradien yang mengalir ke lapisan konvolusi terakhir untuk menghasilkan peta lokalisasi kasar (*coarse localization map*) yang menyoroti region penting dalam citra terhadap keputusan prediksi tertentu. Berbeda dengan metode berbasis piksel seperti *Guided Backpropagation* (Springenberg et al., 2015) yang menghasilkan visualisasi beresolusi tinggi namun tidak diskriminatif terhadap kelas, Grad-CAM bersifat *class-discriminative* yaitu mampu membedakan region yang relevan untuk kelas yang berbeda Selvaraju et al. (2016).

Secara teknis, untuk memperoleh peta lokalisasi $L^c_{\text{Grad-CAM}} \in \mathbb{R}^{u \times v}$ bagi kelas c, pertama dihitung gradien dari skor prediksi y^c (sebelum *softmax*) terhadap aktivasi *feature map* A^k pada lapisan konvolusi tertentu. Gradien tersebut kemudian dilanjutkan ke layer *global average pool* atas dimensi spasial untuk memperoleh bobot kepentingan neuron α^c_k:

$$\alpha^c_k = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A^k_{ij}} \tag{III.2}$$

di mana Z adalah jumlah piksel pada *feature map*, dan indeks i, j merujuk pada posisi spasial. Bobot α^c_k merepresentasikan linearisasi parsial jaringan di hilir A^k dan menangkap *importance feature map* k terhadap kelas c (Selvaraju et al., 2016). *Heatmap* akhir diperoleh sebagai kombinasi linear terbobot dari *forward activation maps* yang dilewatkan fungsi ReLU:

$$L^c_{\text{Grad-CAM}} = \text{ReLU}\left(\sum_k \alpha^c_k A^k \right) \tag{III.3}$$

Penggunaan ReLU pada Persamaan III.3 memastikan bahwa hanya fitur yang berkontribusi *positif* terhadap prediksi kelas c yang divisualisasikan. Piksel dengan nilai negatif cenderung merupakan bukti untuk kelas lain dalam citra (Selvaraju et al., 2016). Selvaraju et al. (2016) juga menunjukkan secara empiris bahwa *global average pooling* memberikan hasil yang lebih baik dibandingkan *global max pooling* karena lebih robust terhadap noise pada gradien.

3.7.2 Implementasi

Grad-CAM diimplementasikan menggunakan library `pytorch-grad-cam`, diterapkan pada lapisan konvolusi terakhir encoder Siamese U-Net sebagaimana disarankan oleh Selvaraju et al. (2016) bahwa lapisan konvolusi terdalam memiliki kompromi terbaik antara semantik tingkat tinggi dan informasi spasial. *Heatmap* yang dihasilkan memiliki resolusi lebih rendah dari input, sehingga di-*upsample* ke resolusi patch asli (256×256) menggunakan interpolasi bilinear sebelum di-*overlay* dengan citra RGB komposit T2.

Karena arsitektur Siamese memiliki dua encoder dengan *shared weights*, Grad-CAM diterapkan secara terpisah pada encoder cabang T1 dan T2 untuk menganalisis perbedaan *attention* model terhadap kedua citra temporal. Pendekatan ini memungkinkan verifikasi apakah model secara konsisten memperhatikan area yang berubah secara spektral, bukan artefak seperti awan atau bayangan.

3.7.3 Sampel Analisis

Analisis dilakukan pada sejumlah sampel representatif yang dipilih secara purposif dari *test set*, mencakup tiga kategori sebagaimana disajikan pada Tabel 1. Sampel *true negative* tidak diikutsertakan karena Grad-CAM menghasilkan aktivasi yang tidak informatif pada kasus di mana model tidak memprediksi kelas *change*, sehingga tidak memberikan wawasan interpretif yang bermakna (Selvaraju et al., 2016).

Tabel 1 Kategori sampel analisis Grad-CAM

Kategori	**Singkatan**	**Tujuan Analisis**
True Positive	TP	Verifikasi model memperhatikan area perubahan nyata
False Positive	FP	Identifikasi artefak yang memicu kesalahan (awan, lahan basah)
False Negative	FN	Identifikasi karakteristik deforestasi yang sulit terdeteksi

3.7.4 Kriteria Validasi Kualitatif

Merujuk pada kerangka evaluasi Selvaraju et al. (2016) bahwa visualisasi yang baik harus bersifat *class-discriminative* dan *faithful* terhadap model, *heatmap* pada penelitian ini dinilai valid apabila aktivasi tinggi (*warm region*) secara spasial bertepatan dengan area yang menunjukkan perubahan spektral signifikan antara T1 dan T2 khususnya penurunan nilai NDVI dan peningkatan reflektansi SWIR yang mengindikasikan penghilangan tutupan kanopi. *Heatmap* yang menunjukkan aktivasi dominan pada area awan, bayangan, atau tepi *patch* dianggap sebagai indikasi model yang tidak reliabel, konsisten dengan analisis *failure mode* yang didemonstrasikan

oleh Selvaraju et al. (2016).

3.8 Analisis Data

Analisis data dilakukan dalam dua tahap: evaluasi kuantitatif performa model dan interpretasi kualitatif melalui XAI.

3.8.1 Metrik Evaluasi Kuantitatif

Evaluasi performa model menggunakan metrik kuantitatif yang dihitung pada level piksel terhadap *test set*, meliputi *Intersection over Union* (IoU), *Precision*, *Recall*, *F1-Score*, *Overall Accuracy* (OA), dan koefisien *Kappa*.

$$\text{IoU} = \frac{TP}{TP+FP+FN} \tag{III.4}$$

$$\text{Precision} = \frac{TP}{TP+FP}, \qquad \text{Recall} = \frac{TP}{TP+FN} \tag{III.5}$$

$$\text{F1-Score} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \tag{III.6}$$

$$\text{OA} = \frac{TP+TN}{TP+TN+FP+FN} \tag{III.7}$$

Koefisien *Kappa* mengukur kesesuaian antara prediksi dan ground truth dengan mempertimbangkan kesepakatan acak (*chance agreement*):

$$\text{Kappa} = \frac{p_o - p_e}{1 - p_e} \tag{III.8}$$

di mana p_o adalah nilai OA, dan p_e merupakan probabilitas kesepakatan teoritis secara acak yang dihitung dengan:

$$p_e = \frac{(TP+FP)(TP+FN)+(TN+FP)(TN+FN)}{(TP+TN+FP+FN)^2} \tag{III.9}$$

IoU dipilih sebagai metrik primer karena merupakan standar evaluasi pada tugas segmentasi biner dan secara langsung mengukur kualitas *change map* yang dihasilkan. F1-Score, OA, dan koefisien Kappa digunakan untuk memberikan gambaran performa klasifikasi secara komprehensif, khususnya dalam mengukur akurasi keseluruhan dan reliabilitas model terhadap ketidakseimbangan kelas.

3.8.2 Interpretasi Kualitatif XAI

Interpretasi hasil XAI dilakukan dengan menganalisis secara visual *heatmap* Grad-CAM yang dihasilkan dari *test set* pada tiga kategori sampel (TP, FP, dan FN) sesuai kriteria berikut:

1. ***True Positive*** **(TP)**: Verifikasi dilakukan untuk memastikan area dengan tingkat aktivasi tinggi (*warm region*) pada *heatmap* berhimpit secara spasial dengan wilayah perubahan tutupan hutan riil pada citra. Hal ini menunjukkan model membuat keputusan berdasarkan fitur spektral perubahan yang benar, bukan karena *bias* atau *background noise*.

2. ***False Positive* (FP)**: Analisis dilakukan pada area non-deforestasi yang dideteksi sebagai deforestasi oleh model. *Heatmap* digunakan untuk mengidentifikasi penyebab kesalahan, seperti apakah model terdistraksi oleh tutupan awan tipis, bayangan awan, atau perubahan musiman pada vegetasi non-hutan (misalnya lahan basah atau pertanian).

3. ***False Negative* (FN)**: Analisis dilakukan pada area deforestasi yang gagal dideteksi oleh model. *Heatmap* digunakan untuk mengevaluasi apakah model tidak sensitif terhadap spektral deforestasi skala kecil atau karena adanya variasi pantulan spektral yang menyerupai kanopi rapat.

Melalui analisis kualitatif ini, kelemahan spesifik model dapat diidentifikasi untuk perbaikan arsitektur lebih lanjut, serta memberikan tingkat transparansi (*explainability*) yang mendukung kepercayaan pengguna terhadap hasil pemetaan deforestasi.

IV SIMPULAN

Penelitian ini mengusulkan penggunaan arsitektur *Siamese U-Net* untuk deteksi deforestasi di Kalimantan Barat menggunakan citra multitemporal Sentinel-2. Pendekatan ini dipilih karena mampu mengekstrak fitur spasial secara hierarkis melalui struktur *encoder-decoder* U-Net, sekaligus memodelkan perbedaan temporal melalui mekanisme *Siamese* dengan *shared weights*. Teknik *Explainable AI* (XAI) berupa *Grad-CAM* diintegrasikan untuk memberikan interpretabilitas terhadap keputusan model, sehingga area yang berkontribusi terhadap prediksi perubahan dapat divisualisasikan secara spasial.

Preprocessing citra dilakukan melalui *Google Earth Engine* dengan metode *cloud masking* dan *median compositing* untuk meminimalkan pengaruh tutupan awan. Pembagian dataset menggunakan *Pythagorean tiling* untuk menghindari kebocoran data spasial. Evaluasi model direncanakan menggunakan metrik kuantitatif (*F1-score*, *IoU*, *OA*, *Kappa*) serta evaluasi kualitatif melalui analisis *heatmap Grad-CAM*.

DAFTAR PUSTAKA

Ali, F., Labib, S. S., Mahmoud, A., and Fattoh, I. E. (2026). Transsiamunet based transformer-augmented siamese-u-net for precise change detection in satellite imagery. *Scientific Reports*, 16(1):11689.

Bromley, J., Guyon, I., LeCun, Y., Säckinger, E., and Shah, R. (1993). Signature verification using a "siamese" time delay neural network. In Cowan, J., Tesauro, G., and Alspector, J., editors, *Advances in Neural Information Processing Systems*, volume 6. Morgan-Kaufmann.

Chen, H., Qi, Z., and Shi, Z. (2021). Efficient transformer based method for remote sensing image change detection. *CoRR*, abs/2103.00208.

Chen, X. and He, K. (2020). Exploring simple siamese representation learning. *CoRR*, abs/2011.10566.

Cheng, G., Huang, Y., Li, X., Lyu, S., Xu, Z., Zhao, Q., and Xiang, S. (2023). Change detection methods for remote sensing in the last decade: A comprehensive review.

Cheng, Z., Wu, Y., Li, Y., Cai, L., and Ihnaini, B. (2025). A comprehensive review of explainable artificial intelligence (xai) in computer vision. *Sensors (Basel, Switzerland)*, 25(13):4166.

Chrysostomou, C., Neophytides, S. P., Mavrovouniotis, M., and Hadjimitsis, D. G. (2026). Optimized spectral indices for global vegetation and water mapping using sentinel-2. *Scientific Reports*, 16(1):4491.

Copernicus Data Space Ecosystem (n.d.). Sentinel-2. [diakses 2026 Apr 13].

Food and Agriculture Organization (2023). Terms and definitions. FRA 2025. Working Paper Forest Resources Assessment Working Paper No. 194, Food and Agriculture Organization of the United Nations (FAO), Rome, Italy. Accessed 21 November 2024.

Global Forest Watch (2026). Interactive forest change map: West kalimantan, indonesia. Diakses pada 13 April 2026.

Jiang, W., Sun, Y., Lei, L., Kuang, G., and Ji, K. (2024). Change detection of multisource remote sensing images: a review. *International Journal of Digital Earth*, 17(1):2398051.

Kathiroli, R., Madhumitha, P. S., Achyut Prasad, D. C., and Sandhiya, S. (2025). Spatiotemporal analysis of mangroves using median composites and convolutional neural network. *Scientific Reports*, 15(1):26999.

Lei, T., Zhang, S., Lin, S., Liu, T., Lv, Z., Gao, T., Gong, M., and Nandi, A. K. (2026). Remote sensing image change detection using deep learning techniques: a comprehensive survey. *Artificial Intelligence Review*, 59(3):102.

Peng, D., Liu, X., Zhang, Y., Guan, H., Li, Y., and Bruzzone, L. (2025). Deep learning change detection techniques for optical remote sensing imagery: Status, perspectives and challenges. *International Journal of Applied Earth Observation and Geoinformation*, 136:104282.

Purwono, I., Ma'arif, A., Rahmaniar, W., Fathurrahman, H. I. K., Frisky, A., and Haq, Q. M. U. (2023). Understanding of convolutional neural network (cnn): A review. *International Journal of Robotics and Control Systems*, 2:739–748.

Richards, J. A. (2022). *Remote Sensing Digital Image Analysis*. Springer, 6th edition.

Ronneberger, O., Fischer, P., and Brox, T. (2015). U-net: Convolutional networks for biomedical image segmentation. *CoRR*, abs/1505.04597.

Selvaraju, R. R., Das, A., Vedantam, R., Cogswell, M., Parikh, D., and Batra, D. (2016). Grad-cam: Why did you say that? visual explanations from deep networks via gradient-based localization. *CoRR*, abs/1610.02391.

Springenberg, J. T., Dosovitskiy, A., Brox, T., and Riedmiller, M. (2015). Striving for simplicity: The all convolutional net.

Withanage, W. (2024). What is remote sensing and its relevance to the study of environment and development? ResearchGate. Diakses pada April 2026.

Yang, Q., Wang, Z., Liu, S., and Li, Z. (2024). Research on improved u-net based remote sensing image segmentation algorithm.

Youssef, K., Kevin, S., Moon, S., and Bouchard, L.-S. (2023). Landslide susceptibility modeling by interpretable neural network. *Communications Earth & Environment*, 4.

RIWAYAT HIDUP

Penulis dilahirkan di kota Pontianak pada tanggal 16 November 2005 sebagai anak ke-3 dari pasangan Bapak Dian Pramudya dan Ibu Juwairiyah. Pendidikan sekolah menengah atas ditempuh di Madrasah Aliyah Negeri 2 Pontianak dan lulus pada tahun 2023. Pada tahun yang sama, penulis diterima sebagai mahasiswa program sarjana (S-1) di Program Studi Ilmu Komputer, Sekolah Sains Data, Matematika, dan Informatika, IPB University.

Selama menempuh studi S-1 di IPB, penulis aktif dalam berbagai organisasi kemahasiswaan dan kegiatan praktikum. Penulis menjabat sebagai staf di Himpunan Mahasiswa Ilmu Komputer (HIMALKOM) IPB (2024–2025), staf di Pertalian Mahasiswa Kalimantan Barat (PEMAKAB) IPB, serta anggota Cyber Security IPB. Penulis juga dipercaya sebagai *Head of Data-Informatics Division* untuk IT TODAY IPB 2025, Bendahara Agriinformatics 2025 IPB University, serta bertugas sebagai Asisten Praktikum Laboratorium Basis Data IPB pada tahun 2025.

Di luar kegiatan kampus, penulis aktif memperdalam keahliannya di bidang teknologi dengan berpartisipasi dalam Coding Camp yang didukung oleh DBS Foundation dan Dicoding sebagai *AI Engineer Cohort* dan *Machine Learning Cohort*.